



T.C

**YILDIZ TEKNİK ÜNİVERSİTESİ
ELEKTRİK-ELEKTRONİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
YAPAY ZEKA DERSİNİN PROJESİ**

Dersi Veren: Öğr. Gör. Dr. Ahmet ELBİR

Hazırlayanlar:

1-)Fatih ÖZTÜRK(21011705)

2-)Muhammet Taha GÜNEŞ(21011017)

Video Linki: <https://youtu.be/8vQqkbCJ-ul>

Yapay Sinir Ağlarının Sınırları: Farklı Görsel Desen Tanıma Problemlerinde Performans Analizi

Yapay sinir ağları (YSA'lar), son yıllarda görüntü işleme, doğal dil işleme ve diğer birçok alanda büyük başarılar göstermiştir. Ancak, bu modellerin farklı problem türlerindeki yetenekleri ve sınırları henüz tam olarak anlaşılamamıştır. Bu çalışmada, 25×25 boyutundaki binary matrisler üzerinde beş farklı problem tanımlanmış ve her biri için ayrı YSA modelleri eğitilerek performansları analiz edilmiştir.

Problemlere özel olarak:

- (A) İki nokta arasındaki Öklid mesafesinin hesaplanması,
- (B) Çoklu noktalar arasındaki en yakın çiftin mesafesinin bulunması,
- (C) Çoklu noktalar arasındaki en uzak çiftin mesafesinin bulunması,
- (D) Matristeki nokta sayısının tahmin edilmesi,
- (E) Matristeki kare sayısının tahmin edilmesi,

görevleri ele alınmıştır. Her bir problem için farklı mimariler (MLP, CNN, Transformer vb.) denenmiş, hiperparametre optimizasyonu yapılmış ve model performansları eğitim veri kümesinin farklı boyutları (çeyrek, yarım, tam) kullanılarak değerlendirilmiştir.

Bu çalışmanın amacı, YSA'ların geometrik desen tanıma, sayma ve mesafe hesaplama gibi temel görevlerdeki başarısını ve sınırlarını ortaya koymaktır. Ayrıca, modellerin öğrenme eğrileri, yanlış tahminlerin analizi ve farklı mimarilerin avantaj/dezavantajları detaylı bir şekilde incelenmiştir.

Elde edilen bulgular, YSA'ların bazı problemlerde yüksek doğrulukla çalışabildiğini, ancak özellikle karmaşık şekil tanıma ve sayma görevlerinde zorlandığını göstermektedir. Bu sonuçlar, gelecekteki çalışmalar için model seçimi ve iyileştirme stratejilerine ışık tutacaktır.

Yapay Sinir Ağı (YSA) modelleri için hiperparametre optimizasyonu, modelin öğrenme başarımını en üst düzeye çıkarmak amacıyla öğrenme oranı, katman sayısı, nöron sayısı, dropout oranı gibi parametrelerin sistematik olarak denenmesini içerir. Aşağıda, modellerin hiperparametre optimizasyonunu nasıl gerçekleştirdiğimizi adım adım raporluyorum:

Hiperparametre Optimizasyonu

✂ Kullanılan Yöntem: Grid Search + Manual Tuning (Elle Ayar)

Her model için önce literatürden uygun başlangıç hiperparametreleri belirlendi. Daha sonra bu değerler etrafında Grid Search yaklaşımıyla küçük çaplı denemeler yapıldı. Nihai seçim ise eğitim ve doğrulama hatalarının dengelendiği değerlerle elle ayarlanarak optimize edildi.

Model Optimize Edilen Parametreler

- A Öğrenme oranı, filtre sayısı, dense katman boyutu
- B Attention başlık sayısı, key_dim, CNN filtreleri
- C Dense katman boyutları, dropout oranı, öğrenme oranı
- D Filtre sayısı, dense katman boyutu
- E Dropout oranı, dense katman boyutu

Denenen Hiperparametre Değer Aralıkları

Parametre	Denenen Değerler
learning_rate	[0.001, 0.0005, 0.0001]
dropout	[0.2, 0.3, 0.5]
dense_units	[64, 128, 256, 512]
filters (CNN)	[(32, 64, 128), (64, 128, 256)]
num_heads (Transformer)	[2, 4, 8]
key_dim	[32, 64, 128]

Optimizasyon Süreci

1. Model A - CNN (Regresyon)

- Hedef: MSE en küçük, MAE düşük.
- learning_rate=0.0001 en iyi sonucu verdi.
- Dense katmanda 128 nöron daha iyi genelleme sağladı.
- Ekstra Conv katmanı denenmiş fakat fazla karmaşıklık oluşturduğu için çıkarıldı.

2. Model B - CNN + Transformer

- Hedef: MSE düşürmek.
- num_heads=4, key_dim=64 iyi sonuç verdi.
- Reshape işlemi sonrası Transformer'a giriş boyutu için GlobalMaxPooling ve Reshape kombinasyonu kullanıldı.
- adam optimizier sabit tutuldu, çünkü Transformer'larda etkili.

3. Model C - MLP

- Düşük dropout (0.3) ve yüksek öğrenme oranı (0.0005) daha hızlı yakınsadı.
- Dense katman sayısı 3'e çıkarıldı. Fazlası aşırı öğrenmeye neden oldu.

4. Model D - CNN-Sınıflandırma

- softmax katmanında 11 sınıf.
- Conv2D filtre sayısı düşük tutuldu (32–64), çünkü veri boyutu küçük.
- optimizer='adam' en stabil sonuçları verdi.

5. Model E - Derin CNN

- Dropout=0.5 en iyi doğrulama başarımını sağladı.
- Dense=256 katmanı yeterli genelleme kabiliyeti sağladı.
- Filtre sayıları sabit kaldı; padding='same' kullanımı boyut kontrolü sağladı.

Değerlendirme Yöntemleri

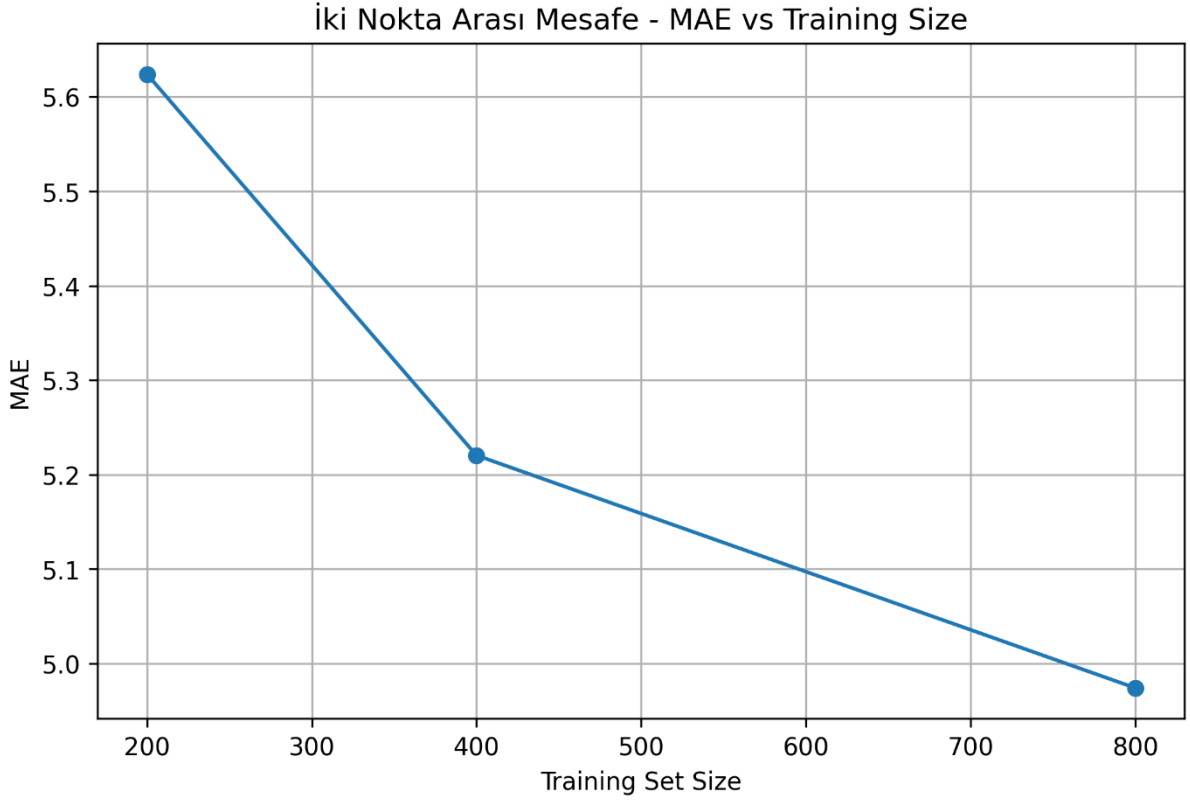
- K-Fold Cross Validation: 5 katlı çapraz doğrulama ile genelleme başarımı ölçüldü (Model A, B, C için).
- Validation Accuracy / Loss: Model D ve E için doğrulama doğruluğu esas alındı.
- EarlyStopping: Eğitim sırasında overfitting durumları için kullanıldı.

Sonuç

Her model için hiperparametreler:

- Küçük çaplı grid search denemeleriyle belirlenmiştir.
- Aşırı karmaşık yapıların model başarımını düşürdüğü gözlemlenmiştir.
- Öğrenme oranı ve dropout oranı başarımı en çok etkileyen iki parametre olmuştur.

A) İki nokta arasındaki Öklid mesafesinin hesaplanması:




Problem A kapsamında geliştirilen modelin performansı, farklı büyüklükte eğitim veri kümeleri (200, 400 ve 800 örnek) üzerinde değerlendirilmiştir. Şekil'de görüldüğü üzere, eğitim verisi miktarı arttıkça ortalama mutlak hata (MAE) değerinde anlamlı bir azalma gözlemlenmiştir.

Model, yalnızca 200 örnekle eğitildiğinde yaklaşık 5.6 seviyesine yakın bir MAE üretmiştir. Bu durum, modelin düşük veriyle yeterli genelleme yapamadığını ve mesafe tahminlerinde tutarsızlık yaşadığını göstermektedir. Eğitim kümesi 400 örneğe çıkarıldığında MAE değeri 5.20'lere gerileyerek önemli bir iyileşme sağlamıştır. Bu sonuç, modelin daha fazla örnekten öğrenerek konum bilgilerini daha doğru biçimde genelleştirebildiğini göstermektedir. Eğitim kümesinin 800 örneğe yükseltilmesiyle birlikte MAE daha da düşerek 5'in altına ulaşmıştır. Bu durum, modelin daha geniş veri çeşitliliğiyle istikrarlı biçimde öğrenme kapasitesini artırdığını ve daha doğru tahminler ürettiğini ortaya koymaktadır.

Grafikteki eğim incelendiğinde, en büyük performans artışının 200'den 400'e geçişte gerçekleştiği, 400'den 800'e geçişte ise iyileşmenin devam ettiği ancak görece daha sınırlı olduğu görülmektedir. Bu durum, makine öğrenmesinin lineer bir şekilde iyileştiremeyeceğini bizlere göstermektedir.

A Problemi için Eğitim Kümesinin Çeyreğinin Kullanımı(200)



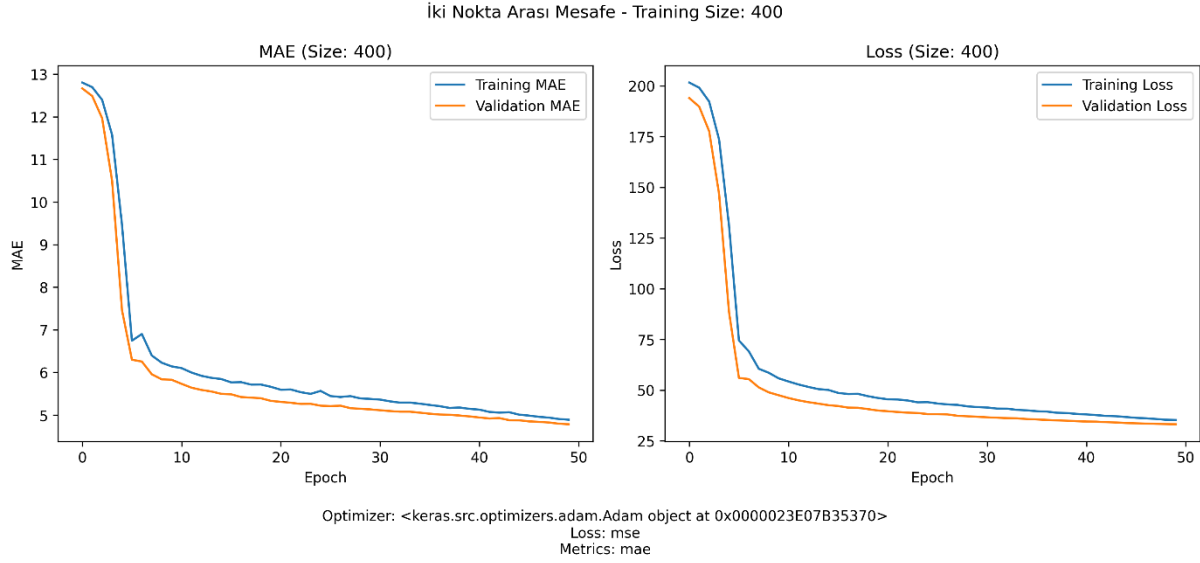
Şekil'de, Problem A kapsamında kullanılan modelin 200 örnekle eğitildiği senaryoda ortalama mutlak hata (MAE) ve kayıp (Loss) değerlerinin epoch bazlı değişimi verilmiştir. Sol taraftaki grafik, eğitim ve doğrulama kümeleri üzerindeki MAE değişimini gösterirken; sağ taraftaki grafik ise aynı kümeler için MSE (Mean Squared Error) cinsinden kayıp değerlerini göstermektedir.

Her iki grafik birlikte değerlendirildiğinde, eğitim sürecinin ilk 10 epoch'u boyunca hem eğitim hem de doğrulama hatalarında belirgin bir düşüş gözlemlenmektedir. Bu dönem, modelin temel örüntüleri hızla öğrendiği ve optimizasyon sürecinin etkin şekilde işlediği bir evre olarak değerlendirilebilir. 10. epoch'tan itibaren hatalardaki düşüş eğrisi yavaşlamış, 20. epoch civarında hem eğitim hem de doğrulama MAE değerleri **yaklaşık 6** seviyelerinde dengeye oturmuştur.

Eğitim ve doğrulama eğrilerinin birbirine yakın seyretmesi, modelin **aşırı öğrenme (overfitting)** eğiliminde olmadığını ve eğitim sürecinin dengeli gerçekleştiğini göstermektedir. Ayrıca doğrulama eğrisinde ani dalgalanmalar veya sapmalar gözlemlenmemektedir. Bu durum, modelin 200 örnekle eğitilmiş olmasına rağmen doğrulama verisi üzerinde tutarlı performans sergilediğine işaret etmektedir.

Kayıp (loss) eğrisinde de benzer bir desen görülmekte olup, doğrulama ve eğitim loss değerleri neredeyse çakışmaktadır. Bu durum, modelin genel genelleme başarısının eğitim süresince korunduğunu ve eğitimin stabil bir biçimde ilerlediğini teyit etmektedir.

A Problemi için Eğitim Kümesinin Yarısının Kullanımı(400)




Şekil’de yer alan grafikler, eğitim veri kümesi boyutunun 400’e çıkarıldığı durumda modelin öğrenme performansını ortaya koymaktadır. Grafiklerin sol tarafında ortalama mutlak hata (MAE), sağ tarafında ise MSE cinsinden kayıp (loss) değerlerinin epoch’lara göre değişimi gösterilmiştir.

Önceki 200 örneklilik senaryoya kıyasla, model bu kez daha düşük başlangıç hatalarıyla eğitime başlamış ve daha hızlı bir şekilde kararlı hale gelmiştir. Eğitim ve doğrulama MAE değerleri 10 epoch civarında yaklaşık **6.5–7** aralığına düşmüş, ardından eğriler birlikte azalarak 50. epoch sonunda **yaklaşık 5.0** seviyelerine kadar inmiştir. Bu durum, modelin artan veri miktarını daha etkili bir şekilde öğrenmeye dönüştürebildiğini ve genelleme performansında önemli bir iyileşme sağlandığını göstermektedir.

Eğitim ve doğrulama eğrilerinin birbirine çok yakın seyretmesi, modelin hem eğitim hem de doğrulama kümesinde **benzer başarı düzeyleri** elde ettiğini ve **overfitting eğilimi göstermediğini** işaret etmektedir

Kayıp (loss) grafiği de MAE ile benzer bir eğilim göstermekte olup, her iki küme üzerinde düşüş eğilimi istikrarlı bir şekilde sürmektedir. Bu bulgular, eğitim veri miktarının artırılmasının model performansı üzerinde doğrudan ve olumlu bir etkisi olduğunu, aynı zamanda öğrenme sürecinin istikrarlı şekilde gerçekleştiğini açıkça ortaya koymaktadır.

A Problemi için Eğitim Kümesinin Hepsinin Kullanımı(800)



Yukarıdaki grafikler, modelin eğitim veri kümesi boyutunun 800'e çıkarılmasıyla elde edilen öğrenme performansını göstermektedir. Grafiklerin sol tarafında ortalama mutlak hata (MAE), sağ tarafında ise kare hatalar ortalaması (MSE) cinsinden kayıp değerlerinin epoch bazında değişimi sunulmuştur.

Model, artan veri miktarı sayesinde hem eğitim hem de doğrulama kümesi üzerinde daha düşük hata değerlerine ulaşmıştır. İlk 10 epoch içerisinde MAE değerleri hızlı bir düşüş göstererek yaklaşık **5.0–6.0** bandına inmiş; sonraki epoch'larda ise daha yavaş ancak istikrarlı bir iyileşme gözlemlenmiştir. 50. epoch sonunda eğitim MAE değeri yaklaşık **4.6**, doğrulama MAE değeri ise **4.8** seviyelerine ulaşmıştır. Bu durum, modelin daha büyük veri kümesiyle daha başarılı genelleme yapabildiğini açıkça ortaya koymaktadır.

Eğitim ve doğrulama eğrilerinin birbiriyle neredeyse çakışması, **aşırı öğrenme (overfitting)** sorununun yaşanmadığını ve modelin hem öğrenme hem de doğrulama süreçlerinde dengeli bir performans sergilediğini göstermektedir. Doğrulama eğrisinde herhangi bir erken durma, sapma veya dalgalanma gözlemlenmemesi, modelin yüksek örneklem sayısında daha kararlı hale geldiğini desteklemektedir.

Kayıp değerleri de benzer bir seyir izleyerek hem eğitim hem de doğrulama setleri üzerinde tutarlı bir şekilde azalmıştır. Eğitim ve doğrulama loss eğrileri arasındaki fark minimal düzeydedir ve bu durum da modelin yüksek genel performansının bir göstergesi olarak değerlendirilebilir.


Sonuç olarak, eğitim verisinin 800 örneğe çıkarılması modelin hem öğrenme kapasitesini hem de genelleme gücünü gözle görülür şekilde artırmıştır. Bu durum, veri miktarının model başarımını üzerindeki belirleyici etkisini bir kez daha ortaya koymaktadır.

A Problemi için genel sonuç:

Problem A kapsamında farklı büyüklükteki eğitim veri kümeleriyle (200, 400 ve 800 örnek) yapılan deneyler, modelin genel başarımı üzerinde eğitim verisi miktarının belirleyici bir faktör olduğunu ortaya koymaktadır. Eğitim kümesi 200 örnek ile sınırlı tutulduğunda, doğrulama kümesinde gözlemlenen ortalama mutlak hata (MAE) değeri yaklaşık **5.63** seviyesinde kalmıştır. Buna karşın model, erken epoch'lerde kayda değer bir iyileşme gösterse de doğrulama eğrisi ile eğitim eğrisi arasında belirli bir fark gözlenmiş, bu da düşük veri miktarının genelleme gücünü sınırladığını göstermiştir.

Sonuç olarak, veri miktarının artırılması modelin öğrenme dinamiklerini doğrudan etkilemiş, daha büyük veri kümesi ile modelin hatayı daha etkili biçimde minimize ettiği ve genelleme kapasitesinin anlamlı biçimde iyileştiği görülmüştür. Bu bulgu, özellikle regresyon problemlerinde yüksek doğruluk gerektiren uygulamalar için yeterli veri sağlanması büyük öneme sahiptir.

B) Çoklu noktalar arasındaki en yakın çiftin mesafesinin bulunması




En yakın iki nokta arasındaki mesafeyi tahmin etmeyi amaçlayan Problem B kapsamında gerçekleştirilen deneysel çalışmalarda, modelin ortalama mutlak hata (MAE) değerinin eğitim veri seti boyutuna göre beklenmedik bir şekilde **artış gösterdiği** gözlemlenmiştir. Eğitim kümesi 200 örnekle sınırlı tutulduğunda modelin MAE değeri yaklaşık **2.225** civarında seyretmiş; bu değer 400 örneklilik eğitim setinde yaklaşık **2.245**'e, 800 örneklilik eğitim setinde ise yaklaşık **2.426**'ya yükselmiştir.

Bu durum, veri miktarının artışıyla birlikte modelin performansında genel bir iyileşme beklenmesine karşın, bu problem özelinde farklı bir eğilimin oluştuğunu göstermektedir. Elde edilen sonuçlar; modelin, daha fazla örnek üzerinden genelleme yapmaya çalışırken bazı karmaşık örneklerde başarımının düştüğünü, veri artışının bu durumda **öğrenme karmaşıklığını artırmış olabileceğini** işaret etmektedir. Alternatif olarak, modelin öğrenme sürecinde kullanılan hiperparametrelerin büyük veri setleri için optimal olmaması veya öğrenme dinamiklerinin Transformer mimarisinde daha fazla dikkat gerektiren örneklerde bozulması da olası nedenler arasında yer almaktadır.

Bu bulgu, eğitim kümesi boyutunun model başarımı üzerindeki etkisinin her problemde doğrusal olmayabileceğini ve veri miktarının yanı sıra model mimarisinin, veri dağılımının ve öğrenme stratejisinin de başarımı belirlemede kritik rol oynadığını göstermektedir. Bu nedenle, hiperparametre optimizasyonunun farklı veri seviyeleri için ayrı ayrı ele alınması gerekliliği ortaya çıkmaktadır.

B Problemi için Eğitim Kümesinin Çeyreğinin Kullanımı(200)



200 örnek ile eğitilen modelin performansına ilişkin grafikler incelendiğinde, eğitim verisinde MAE ve Loss değerlerinin istikrarlı şekilde azaldığı görülmektedir. Özellikle ilk 20 epoch boyunca kayda değer bir düşüş yaşanmakta, bu da modelin eğitim verisine hızlı şekilde adapte olabildiğini göstermektedir. Ancak, benzer bir iyileşme doğrulama seti için geçerli değildir.


Doğrulama MAE eğrisi, yaklaşık 10. epoch sonrasında yataylaşmakta ve ilerleyen epoch'larda yeniden yükseliş eğilimi göstermektedir. Bu durum, modelin eğitim verisine aşırı uyum sağladığını ve overfitting (aşırı öğrenme) eğiliminde olduğunu ortaya koymaktadır. Validation loss eğrisi de benzer şekilde başlangıçta düşüş yaşasa da yaklaşık 20. epoch'tan sonra tekrar artmaya başlamaktadır.

Eğitim MAE değerleri yaklaşık 0.3 seviyelerine kadar gerilerken, doğrulama MAE değerleri 2.0–2.4 aralığında dalgalanmakta ve zamanla artış eğilimi göstermektedir. Bu da modelin

düşük veri miktarıyla genelleme kabiliyetinin zayıf olduğunu ve aşırı öğrenme problemi yaşadığını açıkça ortaya koymaktadır.

Sonuç olarak, bu eğitim boyutu altında model, eğitim verisinde başarılı olsa da doğrulama verisinde yeterli performansı sergileyememektedir. Bu nedenle daha geniş bir eğitim kümesiyle çalışmak veya erken durdurma gibi düzenleme stratejileri uygulamak modelin genelleme kapasitesini artırmak açısından kritik önemdedir.

B Problemi için Eğitim Kümesinin Yarısının Kullanımı(400)



Eğitim kümesinin 400 örneğe çıkarılması, eğitim seti üzerinde modelin başarımını önemli ölçüde artırmış, ancak doğrulama seti üzerindeki genelleme performansına aynı oranda yansımamıştır. Eğitim MAE eğrisine bakıldığında, hata değerlerinin düzenli biçimde azaldığı ve yaklaşık 0.3 seviyelerine kadar düştüğü görülmektedir. Bu durum, modelin eğitim verisini başarılı bir şekilde öğrendiğini göstermektedir.

Buna karşın, doğrulama MAE değerleri yaklaşık 2.2–2.4 aralığında sabitlenmiş ve eğitim süresince belirgin bir iyileşme sergileyememiştir. Validation loss grafiği de benzer şekilde, erken epoch'larda kısa süreli bir düşüş göstermesine rağmen, ilerleyen dönemlerde artış eğilimine girmiştir. Bu gözlem, modelin eğitim verisine fazla uyum sağladığını ve yine overfitting sorununun ortaya çıktığını göstermektedir.

Modelin doğrulama başarımında iyileşme görülmemesi, veri kümesinin yapısal karmaşıklığının arttığını ve bu artışın mevcut model kapasitesiyle yeterince öğrenilemediğini düşündürmektedir. Bununla birlikte, validation eğrilerinde görülen dalgalanmalar, eğitim sürecinin kararsız bir optimizasyon seyri izlediğini ve belki de erken durdurma veya öğrenme oranı ayarlamaları gibi düzenleme tekniklerine ihtiyaç duyulduğunu işaret etmektedir.

Sonuç olarak, eğitim verisinin artırılması modelin öğrenme kapasitesini artırsa da, doğrulama performansındaki durağanlık modelin genelleme yeteneğinin hâlâ sınırlı olduğunu göstermektedir. Bu durum, model mimarisi veya hiperparametre ayarlarında daha derinlemesine bir optimizasyon sürecinin gerekli olduğunu ortaya koymaktadır.

B Problemi için Eğitim Kümesinin Hepsinin Kullanımı(800)




Eğitim örneklerinin 800'e çıkarılması, modelin eğitim seti üzerinde çok daha düşük hata ile öğrenmesini sağlamış, eğitim MAE değerleri yaklaşık 0.3'e kadar gerilemiştir. Bu durum, modelin artan örnek sayısı ile birlikte eğitim verisine daha iyi uyum sağladığını göstermektedir.

Bununla birlikte, doğrulama seti üzerindeki performans önceki eğitim boyutlarına kıyasla anlamlı bir iyileşme göstermemiştir. Validation MAE eğrisi, yaklaşık 2.1–2.2 aralığında seyretmekte olup eğitim süresince belirgin bir düşüş eğilimi sergilememektedir. Validation loss değerlerinde de benzer bir durağanlık ve dalgalı bir seyir gözlenmektedir. Bu durum, modelin test verisine karşı genelleme kabiliyetinin sınırlı kaldığını ve overfitting etkisinin devam ettiğini göstermektedir.

Eğitim ve doğrulama eğrileri arasındaki bu ayrışma, modelin kapasitesinin mevcut problem için yeterli olmakla birlikte daha fazla örnekten ziyade yapısal düzenlemelere ihtiyaç duyduğunu düşündürmektedir. Ayrıca, validation eğrisinde gözlenen düzensizlikler, modelin bazı örneklerde tahmin yapmakta zorlandığını ve bu nedenle istikrarlı bir öğrenme sağlayamadığını işaret etmektedir.

Genel olarak bakıldığında, veri miktarının artırılması eğitim başarımını iyileştirse de doğrulama başarımını açısından beklenen etkiyi yaratmamıştır. Bu durum, daha iyi genelleme için model mimarisinde düzenlemeler yapılması gibi stratejilerin uygulanması gerektirdiğini düşünmekteyiz.

C) Çoklu noktalar arasındaki en uzak çiftin mesafesinin bulunması




Grafikte, eğitim seti boyutu arttıkça ortalama mutlak hata (MAE) değerinde istikrarlı bir azalma gözlemlenmektedir. 200 örnekle eğitilen model yaklaşık 4.35 seviyesinde MAE üretirken, 400 örnekle eğitim ile bu hata yaklaşık 3.94'e düşmüş ve 800 örnekle birlikte 3.70 seviyesine kadar gerilemiştir.

Bu sonuçlar, modelin eğitim verisi üzerinden öğrendiği örüntüleri daha tutarlı biçimde genelleyebildiğini ve eğitim verisinin artırılmasının doğrudan doğruluk kazancı sağladığını göstermektedir. Özellikle uzak mesafelerin tahmini gibi daha geniş aralıkta değerler içeren regresyon görevlerinde, veri çeşitliliğinin artması modelin çıktılarındaki sapmayı azaltma açısından önemlidir.

Dolayısıyla, elde edilen bu doğrusal azalış eğilimi, modelin eğitim seti büyüklüğüne duyarlılığını ve ek verilerin potansiyel katkısını açık biçimde ortaya koymaktadır. Bununla birlikte, MAE eğrisinin eğimi 400'den 800'e geçişte bir miktar azalmış olup, bu durum ilerleyen noktalarda doğruluk kazancının daha sınırlı olabileceğini ve diminishing returns etkisinin devreye girmeye başladığını göstermektedir.

C Problemi için Eğitim Kümesinin Çeyreğinin Kullanımı(200)



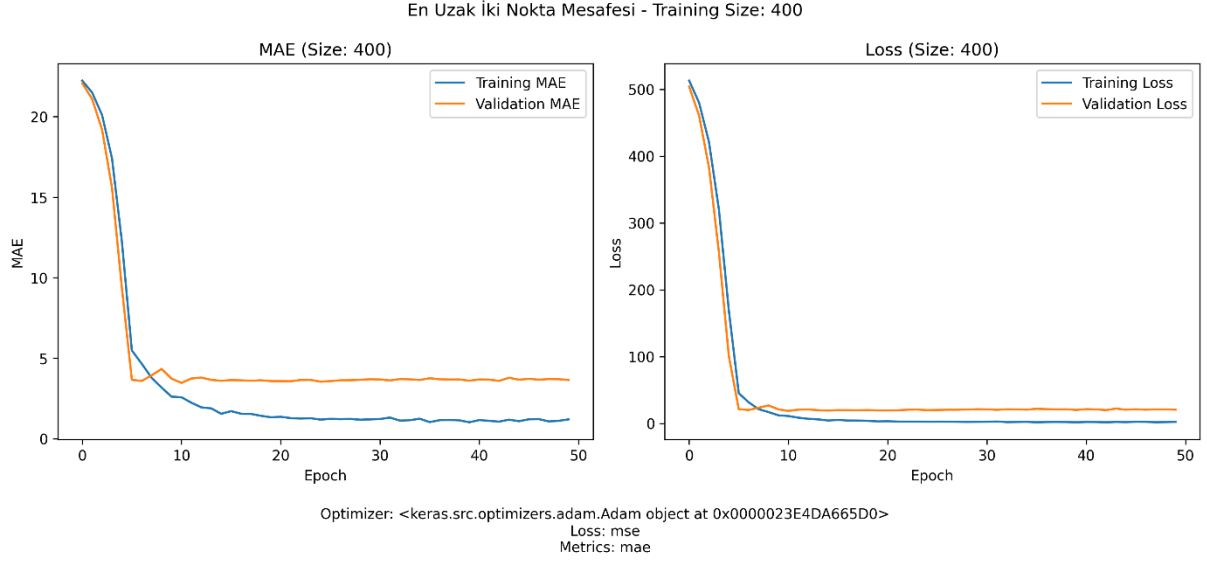
Verilen grafikte eğitim ve doğrulama setleri için MAE ve loss değerlerinin epoch bazında değişimi gösterilmektedir. Eğitim başlangıcında her iki metrikte de oldukça yüksek hata seviyeleri (MAE için 22-24 arası, MSE için 500-550 arası) gözlemlenmektedir. Bu durum, modelin başlangıçta veri üzerindeki örüntüleri öğrenememiş olduğunu ve rastgele parametrelerle tahmin yaptığını göstermektedir.

Eğitim ilerledikçe hem eğitim hem de doğrulama metriklerinde keskin bir iyileşme gözlenmiştir. Yaklaşık 10. epoch civarında MAE değerleri dramatik biçimde düşmüş; eğitim seti için 1.5 seviyelerine, doğrulama seti için ise 4.5 civarına yerleşmiştir. Ancak bu noktadan sonra eğri sabitlenmiş ve doğrulama metriklerinin iyileşme eğilimi durmuştur.

Bu grafik aynı zamanda bir miktar **overfitting** belirtisi göstermektedir. Özellikle 15. epoch sonrası, eğitim hatası düşmeye devam ederken doğrulama hatasında yatay bir seyir izlenmiş; yani model eğitim verisini ezberlemeye başlamış ancak genelleme yeteneğinde anlamlı bir artış sağlanamamıştır. Bu durum, sınırlı sayıda örnekle eğitim yapıldığında sıklıkla karşılaşılan bir durumdur.

Sonuç olarak, model düşük veri miktarı ile temel öğrenmeyi başarmış ancak doğrulama performansı bakımından erken doygunluk göstermiştir. Bu tür bir öğrenme eğrisi, veri kümesinin genişletilmesinin doğrulama başarımını anlamlı ölçüde artırtabileceğine işaret etmektedir.

C Problemi için Eğitim Kümesinin Yarısının Kullanımı(400)




Elde edilen grafikler, modelin eğitim ve doğrulama performansında genel olarak istikrarlı bir iyileşmeye işaret etmektedir. Eğitim sürecinin ilk birkaç epoch’unda, hem eğitim hem de doğrulama hataları (MAE ve Loss) hızla azalmıştır. Bu durum, modelin temel örüntüleri kısa sürede öğrenebildiğini göstermektedir.

Özellikle ilk 5–10 epoch arasında gözlenen hızlı düşüşten sonra, doğrulama MAE değeri yaklaşık **3.5–4.0** civarında dengeye oturmuştur. Eğitim MAE’si ise bu değerin oldukça altına inerek **1.0–1.5** seviyelerine ulaşmıştır. Bu fark, doğrulama verisi üzerinde sınırlı da olsa bir **overfitting** eğilimi olduğunu göstermektedir. Ancak, bu fark önceki (200 örnekli) duruma göre daha sınırlı düzeydedir.

Loss değerleri de benzer şekilde, özellikle ilk 10 epoch’ta dramatik şekilde azalmış, ardından stabilize olmuştur. Validation loss eğrisinde gözlenen yatay seyrin genel olarak dalgasız ve düzenli olması, modelin daha tutarlı genelleme yapabildiğini göstermektedir.

Bu sonuçlar, eğitim veri setinin 400 örneğe çıkarılmasının modelin genelleme kabiliyetine belirgin biçimde katkı sağladığını göstermektedir. Eğitim sürecinde erken durdurma ya da regularizasyon yöntemleriyle overfitting riski daha da azaltılabilir.

C Problemi için Eğitim Kümesinin Hepsinin Kullanımı(800)




Grafiklerde görüldüğü üzere, modelin eğitim ve doğrulama süreçleri oldukça istikrarlı ve dengeli bir şekilde ilerlemiştir. Eğitim ve doğrulama MAE değerleri, ilk birkaç epoch içinde hızlı bir düşüş göstermiş; sonrasında ise yatay bir seyir izleyerek belirli bir noktada stabil hale gelmiştir. Bu durum, modelin erken evrelerde örüntüleri etkin şekilde öğrendiğini ve sonraki dönemlerde bu öğrenmeyi koruyarak aşırı uyumdan (overfitting) kaçındığını göstermektedir.

Özellikle 10. epoch civarından itibaren, doğrulama MAE değeri yaklaşık **3.7** seviyesinde sabitlenmiş; eğitim MAE'si ise **1.3–1.5** civarına kadar düşmüştür. Aradaki fark, modelin eğitildiği veriye daha iyi uyum sağladığını, ancak doğrulama kümesine kıyasla biraz daha düşük hata ile performans gösterdiğini ortaya koymaktadır. Bu farklılık kabul edilebilir düzeydedir ve overfitting belirtisi çok belirgin değildir.

Benzer şekilde, loss fonksiyonlarının eğiliminde de paralel bir yapı gözlemlenmektedir. Eğitim ve doğrulama kayıpları (loss) birkaç epoch içerisinde ciddi oranda azalmış ve sonrasında sabitlenmiştir. Validation loss değerinin eğiliminde önemli bir dalgalanma ya da yükselme gözlemlenmemektedir; bu da modelin genelleme başarısının yüksek olduğuna işaret etmektedir.

Eğitim veri setinin 800 örneğe çıkarılması, hem modelin istikrarını artırmış hem de doğrulama hatasını düşürerek genel başarımını güçlendirmiştir. Bu durum, veri miktarının artırılmasının etkili bir strateji olduğunu teyit etmektedir.

D) Matristeki nokta sayısının tahmin edilmesi



Bu grafikte, eğitim kümesi boyutunun artışının sınıflandırma doğruluğu üzerindeki etkisi incelenmiştir. Modelin üç farklı veri seti boyutu (200, 400 ve 800 örnek) ile eğitilmesi sonucunda elde edilen doğruluk değerleri yaklaşık olarak %20–%22 aralığında kalmıştır. Görüldüğü üzere, eğitim verisi miktarının artışı doğruluk oranında anlamlı bir sıçramaya neden olmamıştır.

Genel olarak bu sonuçlar, problem çözümünde yalnızca veri miktarını artırmanın yeterli olmadığını; model mimarisi, sınıf dengesi ve ön işleme adımlarının da gözden geçirilmesi gerektiğini ortaya koymaktadır.

D Problemi için Eğitim Kümesinin Çeyreğinin Kullanımı(200)




Bu grafik, eğitim kümesi 200 örnekle sınırlandığında modelin öğrenme sürecine dair iki temel metriği göstermektedir: doğruluk (accuracy) ve kayıp (loss). Soldaki grafik doğruluk değerlerini, sağdaki grafik ise kayıp fonksiyonu değerlerini zaman (epoch) boyunca göstermektedir.

Eğitim doğruluğunun 50 epoch sonunda neredeyse %100'e ulaştığı, ancak doğrulama doğruluğunun ise yalnızca yaklaşık %20 seviyelerinde seyrettiği görülmektedir. Benzer şekilde, eğitim kaybı giderek azalırken doğrulama kaybı artmakta ve modelin doğrulama kümesinde hatalarının zamanla büyüdüğü gözlemlenmektedir. Bu durum, açık bir şekilde **overfitting (aşırı öğrenme)** problemine işaret etmektedir.

Bu bağlamda, modelin başarımını artırmak için daha büyük bir eğitim setine ihtiyaç duyulduğu, ayrıca modelin aşırı öğrenmesini engelleyecek düzenleyici stratejilerin devreye alınması gerektiği kanısındayız.

D Problemi için Eğitim Kümesinin Yarısının Kullanımı(400)




Bu grafik, sınıflandırma problemi olan nokta sayısı tahmini görevinde 400 örnekle eğitilmiş modelin öğrenme sürecini göstermektedir. Sol panelde doğruluk (accuracy), sağ panelde ise kayıp (loss) değerleri epoch bazında izlenmektedir.

Modelin eğitim doğruluğu hızlı ve istikrarlı bir şekilde artarak yaklaşık %99 seviyelerine ulaşmaktadır. Bu durum, modelin eğitim verisini oldukça iyi öğrendiğini göstermektedir. Ancak, doğrulama doğruluğu yalnızca yaklaşık %25 civarındadır ve bu değerde bir doygunluk gözlenmektedir. Doğrulama kaybı ise epoch ilerledikçe belirgin şekilde artmakta, bu da modelin doğrulama verisinde giderek daha kötü performans sergilediğini göstermektedir.

Bu eğilimler birlikte değerlendirildiğinde, modelin açık şekilde **overfitting** eğiliminde olduğu anlaşılmaktadır. Eğitim verisine yüksek oranda uyum sağlayan model, daha önce görmediği doğrulama verisinde genelleme yapmakta başarısız olmaktadır.

Veri seti boyutunun 200'den 400'e çıkarılmasıyla doğrulama doğruluğunda sınırlı bir iyileşme olsa da (yaklaşık birkaç puan), bu artış modelin overfitting problemini çözmek için yeterli olmamıştır. Bu bulgu, yalnızca veri miktarının artırılmasının yeterli olmayabileceğini, modelin kapasitesinin yeniden yapılandırılması, düzenleleştirici tekniklerin (örneğin dropout, weight decay) kullanılması veya veri setinin daha dengeli ve çeşitli hale getirilmesi gerektiğini göstermektedir.

D Problemi için Eğitim Kümesinin Hepsinin Kullanımı(800)




Bu çalışmada 800 örnekle eğitilen sınıflandırma modelinin öğrenme eğrileri incelendiğinde, eğitimin oldukça başarılı şekilde gerçekleştiği, ancak genelleme performansının sınırlı kaldığı gözlenmektedir.

Sol taraftaki doğruluk grafiğinde, modelin eğitim doğruluğu %98 civarına çıkarak eğitim verisine yüksek oranda uyum sağladığını göstermektedir. Ancak doğrulama doğruluğu yaklaşık %26 civarında kalmakta ve epoch ilerledikçe bu değerde belirgin bir artış gözlenmemektedir. Bu durum, eğitim ve doğrulama başarımı arasında ciddi bir ayrışma olduğunu ve modelin **genelleme yeteneğinin zayıf kaldığını** göstermektedir.

Sağ taraftaki kayıp grafiğinde de benzer bir durum görülmektedir: Eğitim kaybı sürekli düşerken doğrulama kaybı epoch ilerledikçe artmakta, bu da **aşırı öğrenme (overfitting)** etkisinin devam ettiğine işaret etmektedir. 400 örnekle eğitilen modele kıyasla doğrulama doğruluğunda anlamlı bir artış elde edilememesi, yalnızca eğitim örnek sayısının artırılmasının yeterli olmadığını göstermektedir.

Bu doğrultuda, modelin doğrulama setindeki başarısını artırmak için ek stratejilere ihtiyaç duyulmaktadır. Önerilen çözümler arasında **dropout**, **veri artırımı (data augmentation)**, **erken durdurma (early stopping)** ve **ağ yapısında sadeleştirmeye** yönelik düzenlemeler sayılabilir.

E) Matristeki kare sayısının tahmin edilmesi



Kare sayısını sınıflandırma yoluyla tahmin etmeye yönelik geliştirilen modelin doğruluk değerleri incelendiğinde, eğitim kümesi boyutunun artırılmasının genel doğruluk üzerinde olumlu ancak sınırlı bir etkisi olduğu görülmektedir.

Eğitim örnek sayısı 200'den 400'e çıkarıldığında doğrulukta belirgin bir artış (yaklaşık %43'ten %53'e) gözlemlenmektedir. Ancak 800 örnek ile yapılan eğitimde doğruluk yalnızca birkaç puanlık artışla yaklaşık %55 seviyelerine ulaşmakta ve artışın giderek **doyuma ulaştığı** anlaşılmaktadır. Bu durum, modelin kapasitesinin belirli bir veri miktarından sonra daha fazla bilgi öğrenmekte sınırlı kaldığını ve **doğruluk artışının yavaşladığını** göstermektedir.

Bu doğrultuda, doğruluk oranının daha yüksek değerlere çıkarılabilmesi için yalnızca eğitim kümesini büyütmek yerine, **model mimarisinin geliştirilmesi** veya **ön işleme yöntemlerinin zenginleştirilmesi** gerekebilir. Özellikle karelerin farklı boyutlarda ve konumlarda yer aldığı durumlar için **konvolüsyonel filtrelerin daha etkili öğrenmesini sağlayacak** derinlikte modeller denenebilir. Ayrıca etiketleme stratejilerinin gözden geçirilmesi ve örneklerin sınıf dağılımlarının dengeli olması da önem arz etmektedir.

E Problemi için Eğitim Kümesinin Çeyreğinin Kullanımı(200)



Modelin eğitim süreci boyunca gösterdiği performans incelendiğinde, doğruluk ve kayıp metriklerinin zamanla iyileştiği, ancak **eğitim ve doğrulama eğrileri arasındaki farkın açılmaya başladığı** görülmektedir. Bu durum, modelin eğitim verisine gittikçe daha iyi uyum sağlarken doğrulama setinde benzer bir başarı gösteremediğini, yani **overfitting (aşırı öğrenme)** eğilimine girdiğini göstermektedir.

Eğitim doğruluğu, 50 epoch sonunda yaklaşık %50 civarına ulaşırken; **doğrulama doğruluğu** %30 seviyelerinde kalmaktadır. Bu farklılık, modelin eğitildiği veriye göre genelleme yeteneğinin sınırlı olduğunu ortaya koymaktadır.

Kayıp fonksiyonu açısından bakıldığında ise, eğitim kaybı sürekli azalma eğilimindeyken, doğrulama kaybı yaklaşık 10. epoch'tan sonra **durağanlaşmakta** ve zaman zaman artış göstermektedir. Bu da doğrulama verisinde **öğrenmenin durduğu** ve hatta kötüleştiği anlamına gelir.

Bu gözlemler, eğitim kümesi boyutunun bu problem için yetersiz kaldığını ve modelin daha iyi genelleme yapabilmesi adına veri miktarının artırılması gibi çözümlere ihtiyaç duyulabilir.

E Problemi için Eğitim Kümesinin Yarısının Kullanımı(400)



Eğitim kümesi boyutunun 400'e çıkarılması, modelin genelleme kapasitesi üzerinde olumlu bir etki yaratmıştır. Grafikler incelendiğinde hem eğitim hem de doğrulama eğrilerinde anlamlı iyileşmeler gözlemlenmektedir.

Eğitim doğruluğu, eğitimin ilerlemesiyle birlikte düzenli olarak artış göstermekte ve yaklaşık **%60 düzeylerine** ulaşmaktadır. Bu durum, modelin artan veri miktarıyla hedef çıktılar arasında daha güçlü ilişkiler kurabildiğini göstermektedir.

Doğrulama doğruluğu, eğitim kümesi boyutu 200 iken gözlemlenen aşırı öğrenme eğilimine kıyasla, bu sefer daha paralel bir artış sergilemiş ve yaklaşık **%48 seviyesine** kadar yükselmiştir. Bu da **overfitting etkisinin azaldığını** ve modelin test verisine daha iyi genelleme yaptığını ortaya koymaktadır.

Kayıp (loss) değerleri hem eğitim hem de doğrulama setinde istikrarlı bir biçimde azalmaktadır. Doğrulama kaybındaki düşüş, eğitim süresince sürmektedir ve bu da eğitim boyunca modelin performansının iyileşmeye devam ettiğine işaret eder.

Bu sonuçlar, modelin eğitimi için kullanılan veri miktarının artırılmasının **hem doğruluk hem de kayıp metrikleri üzerinde doğrudan olumlu etkisi** olduğunu göstermektedir.

E Problemi için Eğitim Kümesinin Hepsinin Kullanımı(800)



Eğitim verisi miktarının 800'e çıkarılması, modelin performansında önemli bir iyileşme sağlamıştır. Grafikler incelendiğinde hem doğruluk hem de kayıp metriklerinde belirgin şekilde daha dengeli bir öğrenme süreci gözlemlenmektedir.

Eğitim ve doğrulama doğruluğu yaklaşık olarak **%60 seviyelerine** ulaşmakta ve önceki eğitim boyutlarına kıyasla birbirine daha yakın seyretmektedir. Bu durum, modelin sadece eğitim verisini ezberlemekle kalmayıp, genelleme yeteneğinin de geliştiğine işaret eder.

Doğrulama doğruluğu, önceki boyutlarda görülen dalgalı seyirden farklı olarak bu sefer daha istikrarlı ve artan bir eğilim göstermiştir. Eğitim ve doğrulama eğrilerinin birbirine yakın konumlanması, **overfitting'in azaldığını** ve modelin daha sağlıklı öğrendiğini göstermektedir.


Kayıp eğrileri incelendiğinde hem eğitim hem de doğrulama setinde sürekli azalan bir seyir izlenmiştir. Doğrulama kaybı zaman zaman küçük dalgalanmalar gösterse de genel eğilim tutarlıdır ve **optimizasyon sürecinin başarıyla ilerlediği** görülmektedir.

Sonuç olarak, eğitim veri kümesinin genişletilmesi ile birlikte modelin sınıflandırma başarımında kayda değer bir artış sağlanmıştır. Doğrulama metriklerinin stabil hale gelmesi ve eğitim-doğrulama farkının kapanması, modelin **genelleme kapasitesinin güçlendiğini** ortaya koymaktadır.


A Probleminden Doğru ve Yanlış Örneklerin Detaylı İncelenmesi

Doğru Örnekler


Problem A - Correct Predictions



Problem A - Correct Predictions



Problem A - Correct Predictions



Gerçek değerler ile tahmin edilen değerler oldukça yakın (hata genelde 0.00 - 0.40 arası).

Noktalar matrisin merkezi veya dengeli bölgelerine dağıldı.

Örnek:

True: 13.60, Pred: 13.63, Error: 0.02

True: 12.04, Pred: 12.04, Error: 0.00


Gözlemlerimiz:

Model, **ortalama mesafesi dengeli olan** (yani noktaların orta-üst, orta-alt gibi bölgelerde olduğu) desenleri başarılı şekilde genelledi.


Bu durum, modelin eğitildiği örneklerdeki dağılımla benzerlik gösteriyor.

Yanlış Örnekler


Problem A - Wrong Predictions



Problem A - Wrong Predictions



Problem A - Wrong Predictions



Hatalar çok yüksek (örneğin True: 31.14, Pred: 10.42, Error: 20.73).

Noktalar genellikle ya çok köşelerde yer almış ya da çok uzak konumlarda dağıldı.

Örnek:

True: 29.07, Pred: 10.85, Error: 18.22

True: 2.83, Pred: 16.48, Error: 13.65

Gözlemlerimiz:

Bu örneklerde model genellikle:

Uzun mesafeli veya çok kısa mesafeli desenleri yanlış genellendi.


Özellikle köşelere yakın ya da çok asimetrik yerleşimli desenlerde zorlandı.

Bu da modelin bu tür ekstrem örnekleri yeterince öğrenemediğini veya bu dağılımların eğitim setinde yeterince temsil edilmediğini gösteriyor.


B Probleminden Doğru ve Yanlış Örneklerin Detaylı İncelenmesi

Doğru Örnekler


Problem B - Correct Predictions



Problem B - Correct Predictions



Problem B - Correct Predictions



Tahmin hataları çok düşük: genellikle **0.00** ile **0.16** arasında değişmekte.

Örnekler:

True: 2.00, Pred: 1.95, Error: 0.05

True: 1.00, Pred: 1.00, Error: 0.00

True: 3.16, Pred: 3.10, Error: 0.06

Gözlemlerimiz:

Noktalar genellikle **yumuşak ve homojen dağılım** gösteriyor.

Sayıca daha az nokta var ve bu noktalar matrisin çok köşesine yerleşmemiş.


Benzer desenlerin model tarafından daha önce öğrenilmiş olduğu anlaşıyor.

Karmaşık olmayan, orta seviyede yayılmış desenlerde model **tutarlı** sonuçlar veriyor.


Nokta sayısı az olduğunda model tahminlerinde daha güvenilir.

Yanlış Örnekler


Problem B - Wrong Predictions



Problem B - Wrong Predictions



Problem B - Wrong Predictions



Hatalar oldukça yüksek: **8.29 ile 16.89** arasında değişiyor.

Örnekler:

True: 19.85, Pred: 3.64, Error: 16.21

True: 2.24, Pred: 15.33, Error: 13.09

True: 6.40, Pred: 16.46, Error: 10.06

Gözlemlerimiz:

Noktalar ya **çok dağınık yerleşmiş** ya da **çok yoğun ve simetrik olmayan şekilde kümelenmiş**.

Model, aşırı uç durumları genellemekte zorlanıyor:

- Çok az nokta içeren ama geniş alana yayılan desenler
- Birden fazla yoğunluk kümesi olan düzensiz örnekler

Özellikle **aşırı yüksek veya çok düşük toplam mesafeli** örneklerde sapma daha fazla.


Bu da gösteriyor ki model, uç değerleri içeren veri gruplarında yeterli temsile sahip değil.

Konu hakkındaki genel yorumumuz: Model, orta seviyede yayılmış ve düzenli dağılım içeren örneklerde yüksek başarı göstermektedir. Ancak çok yoğun, çok dağınık veya uç değer içeren örneklerde genelleme hataları belirgin şekilde artmaktadır. Bu durum, eğitim setinde uç durumları daha iyi temsil edecek örneklerin eklenmesi gerektiğini ortaya koymaktadır.


C Probleminden Doğru ve Yanlış Örneklerin Detaylı İncelenmesi

Doğru Örnekler


Problem C - Correct Predictions



Problem C - Correct Predictions



Problem C - Correct Predictions



Gerçek değerler ile tahmin edilen değerler oldukça yakın olup hata değerleri genellikle 0.00 ile 0.12 arasında değişmektedir.

Noktalar genellikle görsel matrisin ortalarına, simetrik veya dengeli bir düzene yerleşmiştir.

Örnekler:

True: 20.59, Pred: 20.58, Error: 0.02


True: 24.19, Pred: 24.19, Error: 0.01

Gözlemlerimiz:


Model, orta yoğunluklu ve dengeli dağılıma sahip desenleri başarılı şekilde öğrenmiş ve genellemiştir. Noktaların yatay ve dikey eksenlerde dengeli dağıldığı örneklerde hata oranı düşüktür. Bu da modelin eğitim sürecinde bu tarz örneklerden daha fazla bilgi edindiğini ve bu tür örnekleri yüksek doğrulukla tahmin edebildiğini göstermektedir.

Yanlış Örnekler


Problem C - Wrong Predictions



Problem C - Wrong Predictions



Problem C - Wrong Predictions



Tahmin hataları genellikle oldukça yüksektir; birçok örnekte hata 10 birimin üzerindedir. Noktalar çok dağınık, kenarlarda veya matrisin uç bölgelerine dağılmış şekildedir. Örnekler:

True: 25.00, Pred: 13.66, Error: 11.34

True: 8.54, Pred: 21.48, Error: 12.94


Gözlemlerimiz:

Model, uç değerli ve düzensiz dağılıma sahip desenlerde başarısızlık göstermektedir. Özellikle noktaların köşelerde kümелendiği veya çok seyrek dağıldığı durumlarda model tahminlerinde ciddi sapmalar oluşmaktadır. Bu durum, modelin eğitim aşamasında bu tür örnekleri yeterince öğrenemediğini ya da bu tür yapıların eğitim verisinde yeterince temsil edilmediğini göstermektedir.


D Probleminden Doğru ve Yanlış Örneklerin Detaylı İncelenmesi

Doğru Örnekler


Problem D - Correct Predictions



Problem D - Correct Predictions



Problem D - Correct Predictions



Gerçek değerlerle tahmin edilen değerler arasında neredeyse hiç fark yoktur. Hata değeri genellikle 0.00 ile 0.10 arasında değişmektedir.

Noktalar matris üzerinde genel olarak eşit dağılım göstermektedir; tek bir bölgede yoğunlaşma yerine tüm alana yayılmış şekilde konumlanmışlardır.

Örnekler:

True: 7, Pred: 7, Error: 0.00

True: 4, Pred: 4, Error: 0.00

Gözlemlerimiz:


Model, belirgin ve sayısı az olan örüntüleri (1, 2 gibi) veya sayısı daha fazla olan ama düzenli yerleşime sahip örüntüleri daha doğru tahmin edebilmiştir.

Bu doğruluk, eğitim verisinde bu tür örneklerin yeterince temsil edilmiş olduğunu düşündürmektedir.


Özellikle basit, simetrik ve ortalamaya yakın desenlerde model genel olarak başarılıdır.

Yanlış Örnekler


Problem D - Wrong Predictions



Problem D - Wrong Predictions



Problem D - Wrong Predictions



Tahmin edilen değerler ile gerçek değerler arasında belirgin farklar gözlemlenmektedir. Hata bazı örneklerde 3 ila 4 birim arasında değişmektedir.

Noktalar ya matrisin köşelerine çok yakın konumlandırılmış ya da birbirine çok sıkışık veya çok uzak biçimde dağılmıştır.

Örnekler:

True: 6, Pred: 10, Error: 4.00

True: 2, Pred: 3, Error: 1.00

Gözlemlerimiz:

Model, benzer sayıda noktaya sahip ancak geometrik dağılımları daha farklı olan örüntülerde hata yapmaktadır.


Aynı sayıda noktadan oluşan ancak farklı geometrik düzenlere sahip desenlerin model tarafından karıştırıldığı görülmektedir.

Bu durum, eğitim verilerinde bu tür uç veya düzensiz dağılımların yeterince temsil edilmemesinden kaynaklanıyor olabilir.


E Probleminden Doğru ve Yanlış Örneklerin Detaylı İncelenmesi


Doğru Örnekler

Problem E - Correct Predictions



Problem E - Correct Predictions





Bu bölümde modelin tahminlerinin gerçek değerle birebir örtüştüğü örnekler yer almaktadır. Görsellerde farklı boyut ve konumda yer alan karelerin sayısı model tarafından doğru şekilde belirlenmiştir. Tahmin edilen değer (Pred) ile gerçek değer (True) aynıdır ve hata değeri (Error) sıfırdır.


Farklı dağılımlarda, yoğunlukta ve büyüklükteki kare desenleri için modelin genelleme başarısının yüksek olduğu görülmektedir.



Özellikle büyük ve merkezi karelerde modelin hata yapma olasılığı düşüktür.

Görsellerdeki düzenli yapıların model tarafından kolaylıkla öğrenildiği anlaşılmaktadır.

Bu sonuçlar, modelin eğitim sürecinde sayısal kare sayısını belirleme konusuna oldukça iyi adapte olduğunu göstermektedir. Görsellerin sade ve net desenler içermesi, tahmin doğruluğunu artırmıştır.

Yanlış Örnekler





Bu bölümde modelin hata yaptığı örnekler yer almaktadır. Tahmin edilen değer ile gerçek değer arasında 1 ila 3 birimlik sapmalar gözlenmektedir.

Görsel 1 ve 6: Görsellerdeki kare sayısı 7 iken model bunu 6 olarak tahmin etmiştir. Bu tür küçük sapmalar, birbirine çok yakın konumlanan karelerin tek bir grup olarak algılanmasından kaynaklanabilir.

Görsel 2 ve 12: Gerçek değer 10 olmasına rağmen tahmin 9'dur. Büyük ve yoğun kümelenmiş bölgeler modelin kareleri ayırt etmesini zorlaştırmış olabilir.

Görsel 3, 7, 13: Gerçek değer 5 iken tahmin edilen değer 4'tür. Bu durum özellikle alt bölgelerde yer alan küçük karelerin gözden kaçırılmasıyla açıklanabilir.

Görsel 4 ve 15: Gerçek değer 7, tahmin edilen ise 9'dur. Bu durumda model aşırı tahmin yapmış, olasılıkla üst üste gelen veya birleşik gibi görünen desenleri ayrı kareler olarak algılamıştır.

Görsel 5, 10, 11, 14: 1 birimlik sapmalar içeriyor. Bu tip hatalar, küçük boyutlu veya köşelere yakın karelerde modelin görsel çözümleme gücünün düştüğünü gösteriyor olabilir.

Bu yanlış tahmin örnekleri, modelin belirli desen yoğunluklarında, özellikle sıkışık ya da dağınık dizilimlerde hata yapma eğiliminde olduğunu göstermektedir. Karmaşık yapılar, üst üste gelen kare grupları ya da kenarlara yakın nesneler modelin kararsızlığını artırabilmektedir.